

INSA

AI 기반 고 디지털 미디어 복원 기술

팀원: 강신실, 김윤나, 노지수




연구 목적



오래된 디지털 영상 자료



사진 출처: MBC



색감 보정과 동시에 화질 개선

연구 목적



Original



Deoldify





Instance-aware Image Colorization

Deoldify의 한계점

- 여러 개체에 대해 처리하지 못하여 결과적으로 색깔이 편향됨

Instance-aware Image Colorization

- 여러 개체에 대해서 처리 가능한 장점
- Deoldify의 단점 보완



NoGAN의 한계점

- Training 과정에서 최소 141,971개(1%)의 ImageNet data가 필요
- Stable한 model을 한번에 찾기 어려움

SinGAN

- 한 장의 Image로 학습 가능
- Multi-scale 구조를 통해서 Stable한 학습 가능



NoGAN 기반 이미지, 영상 색채



**Instance-aware
Image Colorization**



SinGAN
Super-resolution

INSA

연구 과제 아이디어

연구 과제 아이디어



Instance-aware Image Colorization


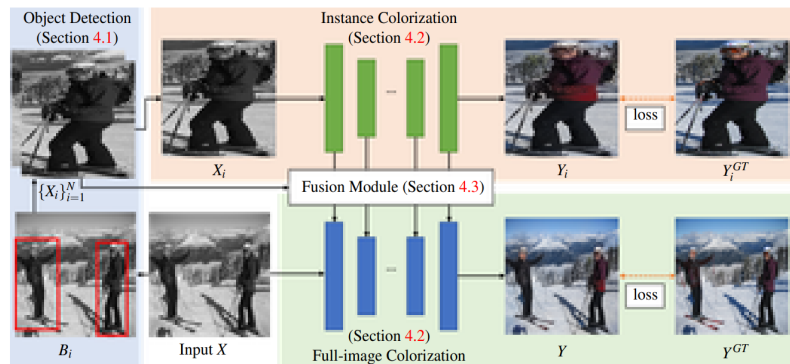


색감 보정



SinGAN

화질 개선






색감 보정 (Instance-aware Image Colorization)



이미지에서 인식된 각 개체에 대해서 색을 입히고 전체 이미지와 융합되도록 이미지 색감 보정

화질 개선 (SinGAN)



한 장의 이미지로 학습된 SinGAN 모델의 Multi-scale 파이프라인을 통해 이미지 화질 개선

색감 보정

Instance-aware Image Colorization

Instance-aware Image Colorization (IEEE, 2020)



이전 Image Colorization 기법 특징



색상이 편향된 예시

- Neural Network을 활용하여 흑백의 이미지에 색상을 입혀 직접 매핑
- 기존 모델이 전체 이미지에 대한 학습 및 통합을 수행하기 때문에
여러 Instances(개체)를 포함하는 이미지의 경우에는 색상이 편향되는 경우가 있음

Instance-aware Image Colorization (IEEE, 2020)



(a) Input

(b) Deoldify [1]

(c) Zhang *et al.* [41]

(d) Ours

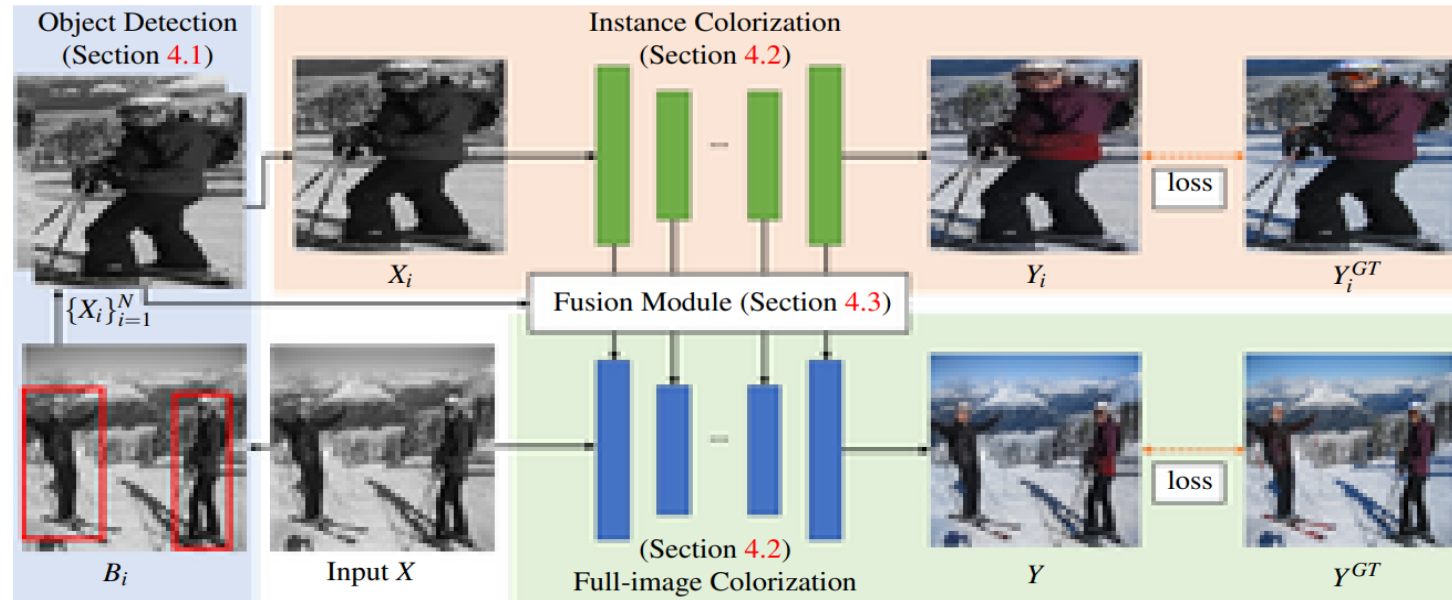
객체가 다양하게 있을 경우,

(b)DeOldify와 **(c)iDeepColor**는 Colorization이 잘 적용이 안 됨

Instance-aware Image Colorization (IEEE, 2020)



Method Overview



1. **Object Detection** : 이미지 내에 객체 별로 이미지를 잘라낸다.
2. **Instance / Full-image Colorization** : 잘린 이미지들과 전체 이미지 별로 기존의 잘 알려진 Mask R-CNN을 적용하여 Colorization을 한다.
3. **Fusion Module** : 잘린 이미지들과 전체 이미지를 합성한다.

Instance-aware Image Colorization (IEEE, 2020)




Table 1. **Quantitative comparison at the full-image level.** The methods in the first block are trained using the ImageNet dataset. The symbol * denotes the methods that are finetuned on the COCO-Stuff training set.

Method	Imagenet ctest10k			COCOStuff validation split			Places205 validation split		
	LPIPS ↓	PSNR ↑	SSIM ↑	LPIPS ↓	PSNR ↑	SSIM ↑	LPIPS ↓	PSNR ↑	SSIM ↑
lizuka <i>et al.</i> [13]	0.200	23.636	0.917	0.185	23.863	0.922	0.146	25.581	0.950
Larsson <i>et al.</i> [17]	0.188	25.107	0.927	0.183	25.061	0.930	0.161	25.722	0.951
Zhang <i>et al.</i> [38]	0.238	21.791	0.892	0.234	21.838	0.895	0.205	22.581	0.921
Zhang <i>et al.</i> [41]	0.145	26.166	0.932	0.138	26.823	0.937	0.149	25.823	0.948
Deoldify <i>et al.</i> [1]	0.187	23.537	0.914	0.180	23.692	0.920	0.161	23.983	0.939
Ours	0.134	26.980	0.933	0.125	27.777	0.940	0.130	27.167	0.954
Zhang <i>et al.</i> [41]*	0.140	26.482	0.932	0.128	27.251	0.938	0.153	25.720	0.947
Ours*	0.125	27.562	0.937	0.110	28.592	0.944	0.120	27.800	0.957

Table 2. **Quantitative comparison at the instance level.** The methods in the first block are trained using the ImageNet dataset. The symbol * denotes the methods that are finetuned on the COCO-Stuff training set.

Method	COCOStuff validation split		
	LPIPS ↓	PSNR ↑	SSIM ↑
lizuka <i>et al.</i> [13]	0.192	23.444	0.900
Larsson <i>et al.</i> [17]	0.179	25.249	0.914
Zhang <i>et al.</i> [38]	0.219	22.213	0.877
Zhang <i>et al.</i> [41]	0.154	26.447	0.918
Deoldify <i>et al.</i> [1]	0.174	23.923	0.904
Ours	0.115	28.339	0.929
Zhang <i>et al.</i> [41]*	0.149	26.675	0.919
Ours*	0.095	29.522	0.938

LPIPS (값이 낮을 수록 성능이 좋음)와
PSNR, SSIM (값이 높을 수록 성능이 좋음)
을 비교한 결과 DeOldify를 비롯한 다른
모델보다 InstaColorization의 성능이 좋은
것을 확인할 수 있다.



흑백 이미지

DeOldify

InstaColorization

흑백 이미지를 colorization시킨 DeOldify와 InstaColorization


화질 개선

SinGAN


SinGAN (ICCV, 2019)



SinGAN으로 얻는 기대 효과



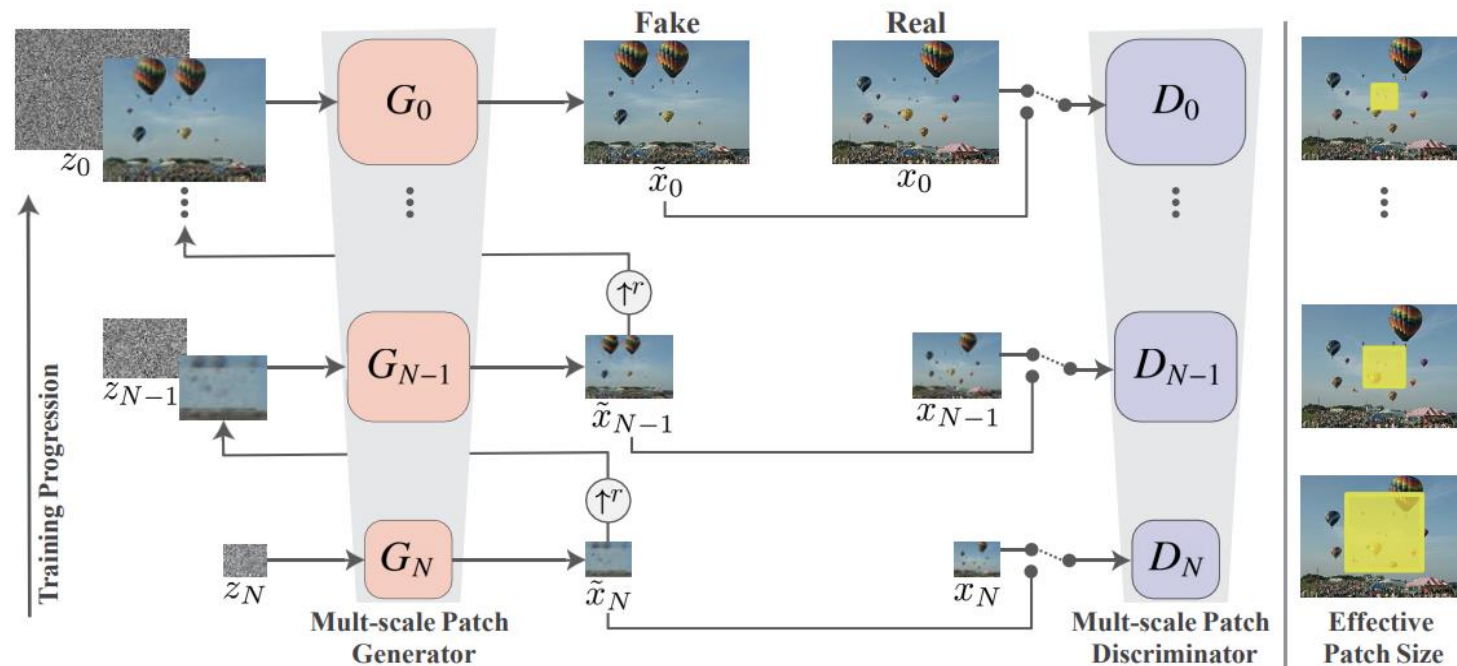
한 장의 이미지를 이용해서
GAN Network를 학습 가능한 Model



Pipeline이 Multi-scale로 되어 있기 때문에
다양한 Application에 쉽게 적용 가능
Multi-scale의 일부분을 사용해서 적용할 예정

SinGAN (ICCV, 2019)

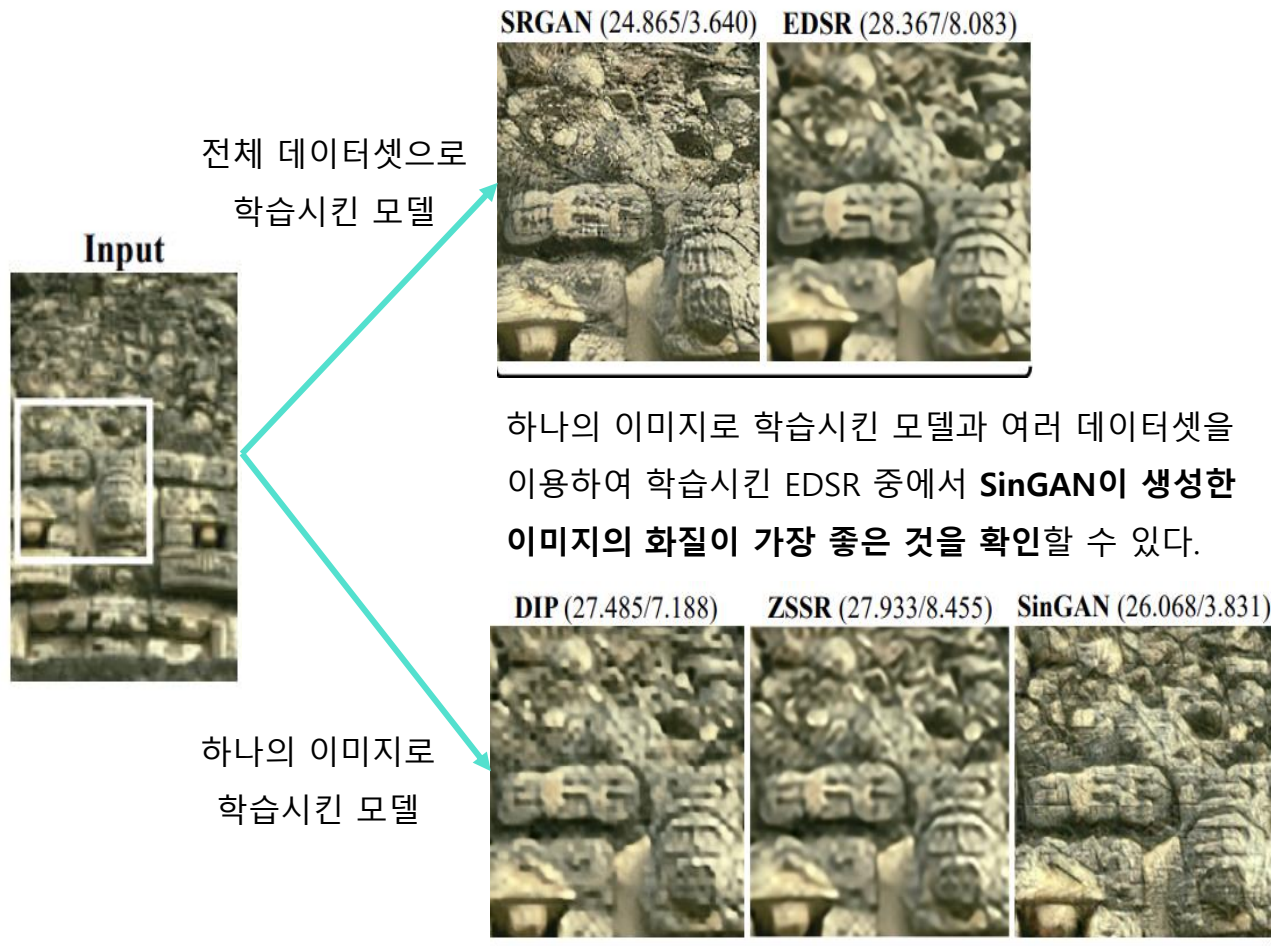
SinGAN's Multi-scale Pipeline



SinGAN은 GAN의 피라미드 구조로 이루어져 있으며,
 Training 과정과 Inference 과정 모두 coarse-to-fine fashion으로 수행된다.
 하나의 Image Data를 이용해서 Image의 다양한 Scale에서의 Patch 분포를 학습한다.

SinGAN (ICCV, 2019)

Super-Resolution Example Result



	SRGAN	EDSR
RMSE	16.34	12.29
NIQE	3.41	6.50

왜곡 정도를 나타내는 **RMSE**와 이미지의 품질을 나타내는 **NIQE** (값이 낮을 수록 성능이 좋음)을 비교한 결과 다른 모델과 비교하여 **SinGAN**의 성능이 비슷하거나 좋은 것을 확인할 수 있다.

	DIP	ZSSR	SinGAN
RMSE	13.82	13.08	16.22
NIQE	6.35	7.13	3.71

연구 과제 수행 계획

실험 세팅



데이터셋

학습 데이터셋

데이터셋	이미지 특징	이미지 개수
ImageNet	<ul style="list-style-type: none">• Image Colorization의 벤치마크 데이터셋으로 많이 쓰임• 객체 중심적 이미지가 주를 이룸	1.3M
COCO-Stuff	<ul style="list-style-type: none">• 객체가 여러 개인 자연 경관 이미지가 주를 이룸	118K

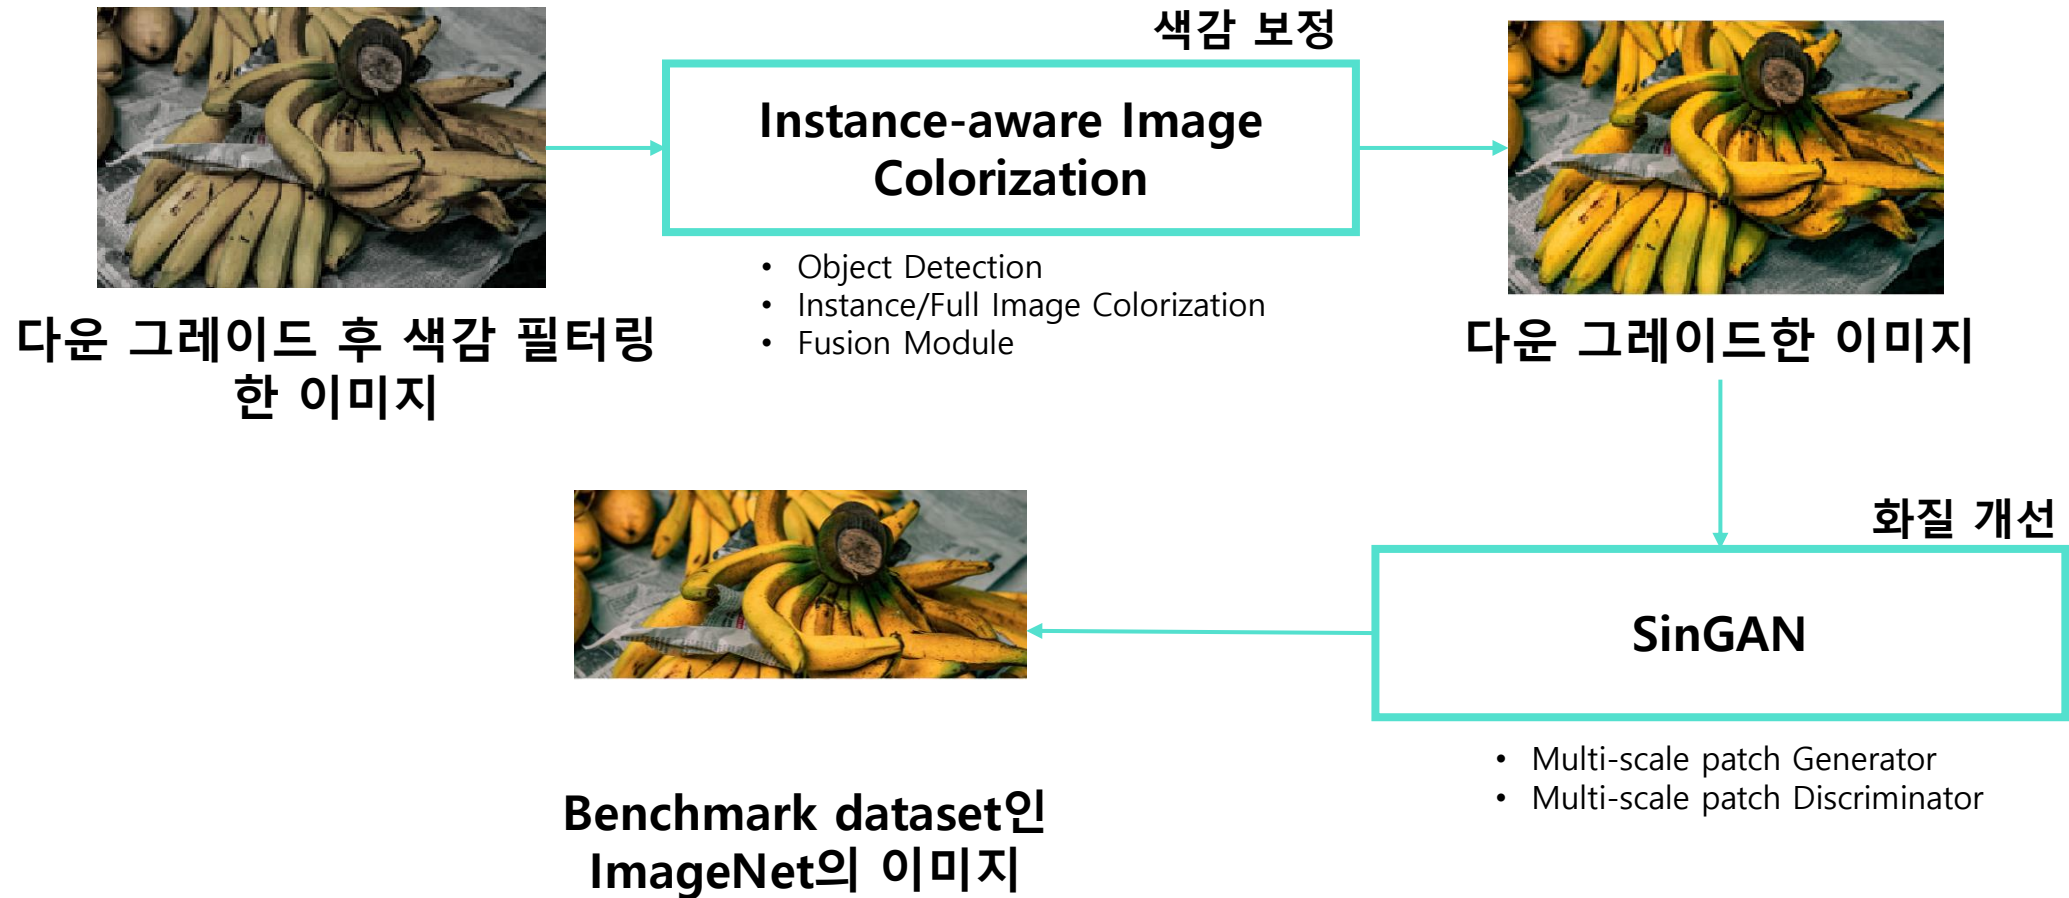
검증 데이터셋

80 90년대 영상 콘텐츠 및 오래된 이미지

모델 구조




End-to-End 모델 구조 - Training



모델 구조




End-to-End 모델 구조 - 최종



INSA

색감 보정 + 화질 개선

일정 계획



예산 사용 계획



- GIGABYTE 지포스 RTX 3090: 400만원
- LG모니터 32UN650 32인치: 50만원
- 기타 부품: 50만원
- 문헌 구입비: 100만원

연구 수행 계획



	강신실	김윤나	노지수
데이터 수집 및 전처리	√		√
색감 보정 모델 분석		√	√
색감 보정 모델 개발			√
화질 개선 모델 분석	√	√	
화질 개선 모델 개발	√		
모델 통합		√	√
모델 튜닝	√	√	√

팀원 소개



강신실 (팀장)

- 서울시립대학교 전자전기컴퓨터공학과 석사과정
- GAN과 VAE를 활용한 추천 시스템 연구
- 2019 X-TWICE 머신러닝 기반 와인 추천시스템 프로젝트 수상
- 2019 빅데이터 연계 경진대회 수상



김윤나

- 서울시립대학교 컴퓨터과학과 석사과정
- 데이터 차원 축소 및 그래프 기반의 추천 시스템
- Object detection을 활용한 장애물 알림 서비스 제작
- zero-shot 기반 화질 개선 프로젝트 진행



노지수

- 서울시립대학교 컴퓨터과학과 석사과정
- Reinforcement Learning 활용한 추천 시스템
- YOLO와 GAN을 활용한 Object Detection&Image Inpainting 프로젝트 진행
- 제 10회 공개SW 개발자대회 본선 진출

Thank you